

Sistema de Recuperación de Información Multimodal con RAG

Joel Quilumba José Sarango Anthony Goyes

Escuela Politécnica Nacional
Recuperación de Información

1. Introducción

Este trabajo presenta el diseño e implementación de un sistema de Recuperación de Información (RI) multimodal capaz de responder consultas conversacionales sobre un corpus compuesto por texto e imágenes. El sistema integra representaciones vectoriales multimodales generadas con CLIP, una base de datos vectorial (ChromaDB), un flujo de *Retrieval-Augmented Generation* (RAG) y una interfaz conversacional web. Adicionalmente se implementan y evalúan las cuatro funcionalidades de excelencia: re-ranking, expansión de consultas, relevance feedback y memoria conversacional.

El objetivo es integrar los conceptos del curso en un sistema moderno de RI, verificando empíricamente el comportamiento de cada componente mediante métricas estándar (Precision@k, Recall@k y NDCG@k) sobre un conjunto de juicios de relevancia reales.

2. Descripción del corpus

El corpus se construyó combinando dos fuentes públicas:

- **ESCI** (*Amazon Shopping Queries Dataset*, Amazon Science): aporta las consultas, los títulos de producto y los juicios de relevancia graduados con etiquetas E (*Exact*), S (*Substitute*), C (*Complement*) e I (*Irrelevant*).
- **SQID** (*Shopping Queries Image Dataset*, Crossing Minds): aporta las URL de las imágenes de cada producto.

Ambas fuentes se unen mediante el identificador de producto (`product_id`). Dado que SQID solo cubre ~ 164.900 de los $\sim 1,2M$ productos de ESCI-US, el muestreo se restringió al universo de productos con imagen disponible *antes* de seleccionar las consultas, garantizando así que la cobertura de imagen fuese prácticamente total y que las métricas de *Recall* resultaran informativas. Se aplicó el filtro estándar de evaluación: `split = test`, `locale = us` y un mínimo de 5 juicios por consulta.

El corpus final resultante se resume en la Tabla 1. La cobertura de imagen alcanzó el 96,2 %, coherente con la reportada por los autores de SQID. Las etiquetas de relevancia se mapearon a ganancias para el cálculo de NDCG: $E = 3$, $S = 2$, $C = 1$, $I = 0$.

Cuadro 1: Composición del corpus final.

Característica	Valor
Consultas (queries)	100
Productos únicos	1.823
Juicios de relevancia	1.839
Cobertura de imagen	96,2 %
Juicios promedio por consulta	~18
Etiqueta E (<i>Exact</i>)	980
Etiqueta S (<i>Substitute</i>)	483
Etiqueta I (<i>Irrelevant</i>)	312
Etiqueta C (<i>Complement</i>)	64

Se observa que la etiqueta C (*Complement*) es minoritaria (3,5 %), lo cual es consistente con su baja frecuencia en el conjunto ESCI completo. Todas las clases están representadas y ninguna consulta carece de documentos relevantes, por lo que el NDCG queda bien definido en todos los casos.

3. Arquitectura del sistema

La Figura 1 muestra la arquitectura general. El flujo se organiza en dos etapas de recuperación seguidas de generación:

1. **Representación (CLIP).** Se emplea el modelo `openai/clip-vit-base-patch32` para proyectar títulos e imágenes a un espacio compartido de 512 dimensiones. Los vectores se normalizan (norma $L2 = 1$), lo que permite emplear el producto punto como similitud del coseno.
2. **Indexación (ChromaDB).** Los embeddings se almacenan en un cliente persistente con métrica coseno, en dos colecciones (títulos e imágenes). No se emplean motores de búsqueda completos, manteniendo el proceso de *scoring* explícito en el código.
3. **Recuperación multimodal.** Una consulta de texto se compara con ambas señales mediante una fusión ponderada:

$$\text{score}(q, d) = \alpha \cdot \cos(q, d_{\text{texto}}) + (1 - \alpha) \cdot \cos(q, d_{\text{imagen}}).$$

4. **Re-ranking (excelencia).** Un *cross-encoder* (`ms-marco-MiniLM-L-6-v2`) reordena el pool de candidatos.
5. **Generación (RAG).** El Top- k recuperado se inyecta como contexto a un modelo de lenguaje (Llama 3.1 vía Groq; adaptador intercambiable con Gemini) que redacta la respuesta en español.
6. **Interfaz.** Aplicación web tipo chat (Gradio) que muestra la respuesta y las evidencias utilizadas (imágenes y puntajes), garantizando la trazabilidad entre recuperación y generación.




Figura 1: Arquitectura general del pipeline de recuperación multimodal con RAG.

4. Pipeline de recuperación y generación

La recuperación devuelve un ranking Top- k ordenado por el *score* fusionado. Para que la fusión sea exacta, se recupera el ranking completo de ambas colecciones y se combinan las similitudes de

cada candidato antes de truncar a k ; a la escala del corpus (~ 1.800 documentos) esta operación es instantánea.

En la etapa de generación, el sistema construye automáticamente el contexto concatenando los títulos recuperados y solicita al modelo de lenguaje una respuesta fundamentada *únicamente* en dicho contexto. El diseño **desacopla recuperación y generación**: si el modelo de lenguaje no está disponible, la interfaz continúa mostrando las evidencias recuperadas. La interfaz presenta, para cada resultado, la imagen asociada, el título y el puntaje de recuperación, cumpliendo el requisito de transparencia.

Sistema de Recuperación de Información Multimodal con RAG

Búsqueda multimodal (CLIP) + re-ranking + RAG + memoria conversacional + relevance feedback + búsqueda por imagen

Conversación

wireless headphones with microphone

Puedo recomendar los siguientes productos:

- Razer BlackShark V2 Pro Wireless Gaming Headset: THX 7.1 Spatial Surround Sound - 50mm Drivers - Detachable Mic - for PC, PS5, PS4, Switch, Xbox One, Xbox Series X|S - Black

También podrías considerar el siguiente producto:

- Producto 4: Razer BlackShark V2 Pro Wireless Gaming Headset: THX 7.1 Spatial Surround Sound - 50mm Drivers - Detachable Mic - for PC, PS5, PS4, Switch, Xbox One, Xbox Series X|S - Black

Escribe tu mensaje (ej: bright solar lights for my garden)

Reiniciar feedback

Evidencias utilizadas

Logitech H390 Wired Headset, Stereo Headphones with Noise-Cancelling Microphone, USB, In-L

score: 3.95 | sim imagen: 0.290 | id: B000UXZQ42

Megusta No me gusta

USB Headset with Microphone Noise Cancelling & Audio Controls, Wideband Computer Headphone

score: 3.76 | sim imagen: 0.301 | id: B08LCNXN6N

Megusta No me gusta

USB Headset with Microphone Noise Cancelling & Mic Mute, Stereo Computer Headphone for Call

score: 1.75 | sim imagen: 0.294 | id: B0LMYYW3UA

Megusta No me gusta

Figura 2: Interfaz conversacional desplegada en Streamlit con respuesta generada y evidencias recuperadas.

5. Resultados experimentales

5.1. Recuperación multimodal: barrido de α

Se evaluó el sistema base variando el peso α entre la señal de texto y la de imagen, sobre las 100 consultas (Tabla 2). El resultado es contundente y contrario a la intuición inicial: la señal de **imagen** ($\alpha = 0$) supera ampliamente a la de **texto** ($\alpha = 1$), duplicando el NDCG@10 (0,624 frente a 0,297). La tendencia es monótona: cuanto mayor es el peso del texto, peor es el desempeño.

Cuadro 2: Barrido de α (promedio sobre 100 consultas). $\alpha = 1$: solo texto; $\alpha = 0$: solo imagen.

α	P@10	R@10	NDCG@10
0,00	0,564	0,450	0,624
0,25	0,513	0,410	0,577
0,50	0,375	0,290	0,437
0,75	0,309	0,237	0,367
1,00	0,244	0,189	0,297

Este comportamiento se explica por la naturaleza de CLIP: su torre de texto fue entrenada para alinearse con imágenes, no para medir similitud texto-texto. En consecuencia, asigna similitudes altas y poco discriminativas ($\sim 0,7-0,8$) a casi cualquier par consulta-título, generando *hubs* (títulos genéricos que aparecen en el Top- k de múltiples consultas). La torre de imagen, en cambio, discrimina

correctamente. Por ello se adopta $\alpha = 0$ como configuración operativa del sistema.

5.2. Excelencia 1: Re-ranking con cross-encoder

Sobre la mejor configuración de recuperación ($\alpha = 0$, pool de 50 candidatos), se aplicó un cross-encoder que reordena por relevancia consulta-título. La Tabla 3 muestra una mejora simultánea en las tres métricas: el NDCG@10 asciende de 0,624 a 0,722, una mejora relativa del **+15,8 %**.

Cuadro 3: Excelencia 1: re-ranking frente al *baseline* (100 consultas).

Sistema	P@10	R@10	NDCG@10
Baseline ($\alpha = 0$)	0,564	0,450	0,624
Re-ranking (pool=50)	0,649	0,524	0,722

La arquitectura resultante es complementaria: la señal de imagen de CLIP recupera un pool amplio (donde CLIP es fuerte) y el cross-encoder aporta la comprensión fina consulta-título (donde CLIP-texto es débil), cubriendo cada componente la debilidad del otro.

5.3. Excelencia 2: Expansión de consultas

Para evaluar la reformulación de consultas conversacionales se generó, con un modelo de lenguaje, una versión conversacional de cada una de las 100 consultas (preservando la intención, por lo que se evalúan con los mismos juicios). Se compararon tres configuraciones (Tabla 4).

Cuadro 4: Excelencia 2: efecto de la expansión de consultas (100 consultas).

Configuración	P@10	R@10	NDCG@10
1. Consulta ESCI original	0,649	0,524	0,722
2. Conversacional sin expansión	0,662	0,543	0,741
3. Conversacional con expansión	0,658	0,528	0,727

El resultado **refuta la hipótesis inicial**: las consultas conversacionales no degradaron el rendimiento (0,741 frente a 0,722), y la expansión no aportó mejora adicional (0,727). El análisis sugiere que el cross-encoder de la etapa de re-ranking, entrenado sobre preguntas en lenguaje natural (MS MARCO), aprovecha directamente el contexto conversacional, haciendo la reformulación redundante *en esta arquitectura de dos etapas*. La expansión conserva valor potencial en configuraciones sin re-ranking, donde la recuperación por embedding es sensible a la dilución del texto largo. Este hallazgo ilustra que la utilidad de un componente depende de su interacción con el resto del sistema, no de su valor aislado.

5.4. Excelencias 3 y 4: Relevance Feedback y Memoria conversacional

Estas funcionalidades, de naturaleza interactiva, se validaron cualitativamente en la interfaz:

- **Relevance Feedback (Rocchio).** El usuario califica productos con “Me gusta”/“No me gusta”; el vector de consulta se desplaza hacia el centroide de los positivos y se aleja del de los negativos ($q' = q + \beta c_+ - \gamma c_-$, con $\beta = 0,5$, $\gamma = 0,3$). Se verificó que un producto marcado negativamente desaparece del Top- k en la búsqueda siguiente, y que al reiniciar el feedback el ranking original se restaura.
- **Memoria conversacional.** Las consultas de seguimiento ambiguas se reescriben como consultas autónomas usando el historial. Por ejemplo, tras “*solar lights for my garden*”, el mensaje “*do you*

have any with flowers?" se reescribe internamente como *"solar lights with flowers"*, modificando efectivamente los documentos recuperados. Si la consulta ya es autónoma, se deja sin cambios.

Sistema de Recuperación de Información Multimodal con RAG

Búsqueda multimodal (CLIP) + re-ranking + RAG + memoria conversacional + relevance feedback + búsqueda por imagen

Conversación ↔

 solar lights for my garden

 Recomiendo los siguientes productos para iluminar tu jardín:

- Aloudy Solar Garden Stake Lights, Upgraded 3 Pack Outdoor Waterproof Solar Powered Lights con 12 flores de lirio de 7 colores cambiantes.
- Solar Lights Outdoor Decorative - 2 Pack Magic Crystal Solar Globe Lights Outdoor Solar Powered Light, Color-Changing LED Solar Garden Stake Lights para patio y jardín.
- Solar Lights Outdoor - New Upgraded Solar Garden Lights, Multi-Color Auto-Changing 8 flores decorativas más grandes para jardín, patio y decoración de jardín.

¿Te gustaría saber más sobre alguno de estos productos?

 do you have any with flowers?

 Recomiendo los siguientes productos con flores:

Evidencias utilizadas

Memoria conversacional: consulta reescrita como 'solar lights with flowers'



Outdoor Solar Garden Stake Lights, Upgraded LED Solar Powered Light with 6 Rose Flowers, 3
score: 7.09 | simImagen: 0.293 | id: B07ZY15W6D

 Me gusta  No me gusta



Aloudy Solar Garden Stake Lights, Upgraded 3 Pack Outdoor Waterproof Solar Powered Lights
score: 6.43 | simImagen: 0.307 | id: B07TJ9LVW

 Me gusta  No me gusta



Upgraded 6 Blue Rose Flowers Solar Garden Stake Lights, Waterproof Solar Flower Garden Lig
score: 5.55 | simImagen: 0.325 | id: B08T68C8QQ

 Me gusta  No me gusta

Figura 3: Evidencia de memoria conversacional mediante reescritura de consulta y recuperación coherente.

6. Análisis de las métricas

Los resultados permiten varias conclusiones sobre el comportamiento del sistema:

- La **modalidad visual domina** la recuperación en este dominio: para ranking consulta-producto, las imágenes de CLIP son considerablemente más discriminativas que sus títulos. Este hallazgo coincide con las limitaciones conocidas de la torre de texto de CLIP sin ajuste fino.
- El **re-ranking es la mejora más efectiva**, elevando el NDCG@10 casi un 16 % relativo. Confirma la utilidad de la arquitectura clásica de dos etapas (recuperación amplia y económica + reordenamiento preciso y costoso sobre un pool reducido).
- La **robustez a la conversacionalidad** del sistema completo indica que el cross-encoder absorbe el ruido del lenguaje natural, un resultado relevante para sistemas conversacionales reales.

Como limitaciones, se destaca que el corpus, aunque suficiente para una evaluación válida, es de tamaño moderado (100 consultas); que la etiqueta *Complement* está poco representada; y que tanto CLIP como ESCI operan en inglés, por lo que la recuperación se realiza en inglés mientras la generación de respuestas se produce en español.

7. Conclusiones

Se implementó un sistema de RI multimodal completo y funcional que satisface la totalidad de los requisitos del proyecto e incorpora las cuatro funcionalidades de excelencia. La evaluación experimental, apoyada en juicios de relevancia reales y métricas estándar, no solo verificó el correcto funcionamiento de cada componente, sino que produjo hallazgos no triviales: la superioridad de la señal visual en CLIP, la notable eficacia del re-ranking y la inesperada robustez del sistema frente a consultas conversacionales. El diseño desacoplado y tolerante a fallos (caché de llamadas, adaptador de proveedor de LLM, degradación elegante ante la ausencia del modelo de lenguaje) refleja además consideraciones prácticas de ingeniería surgidas durante el desarrollo.

8. Enlaces del proyecto

Video demostrativo: [Ver video](#).

Aplicación desplegada: [Abrir aplicación en Streamlit](#).

Repositorio: [Ver repositorio en GitHub](#).